



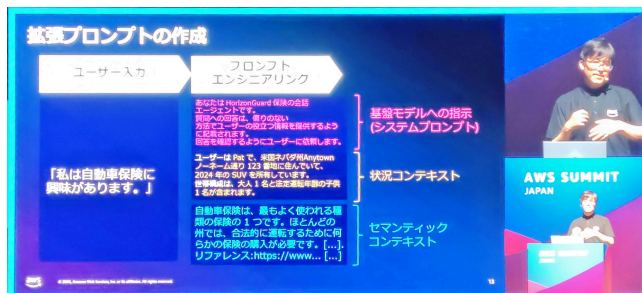
生成AIへのデータ組み込み

2025年6月25日 12:51





拡張プロンプトの設計

基盤プロンプト、状況コンテキスト、セマンティックコンテキスト




アーキテクチャ



応答精度を高めるテクニック

RAGの基本構成



NaiveRAG

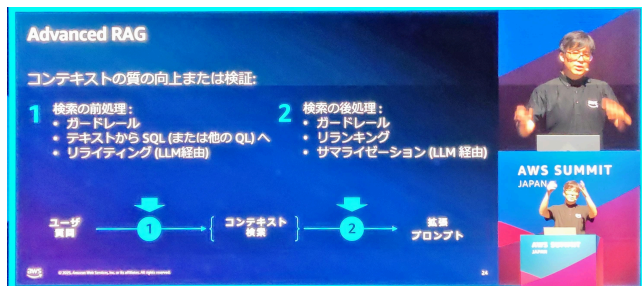
基本的なRAGワークフロー

- データ準備
- シンプルな検索

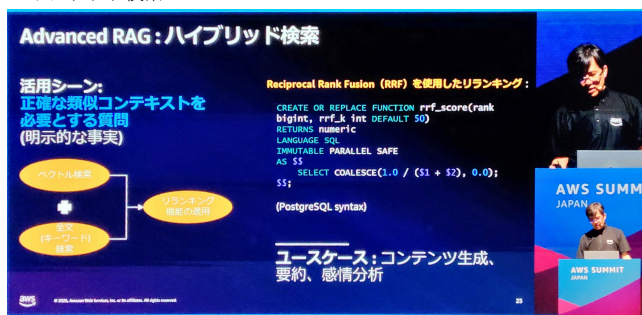
フレームワーク、モデル、データストアなどを設計する

-> データの関係性に誤りがあることがある

AdvancedRAG

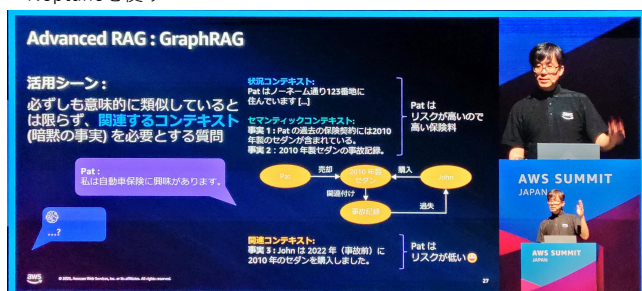


ハイブリッド検索

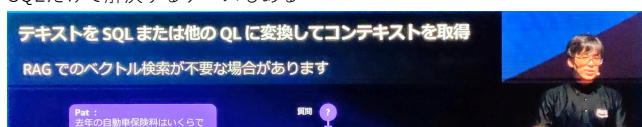



GraphRAG

Neptuneを使う




SQLだけで解決するケースもある






使い分けのポイントは、誰にでも同じ回答でいいか、パーソナライズが必要か

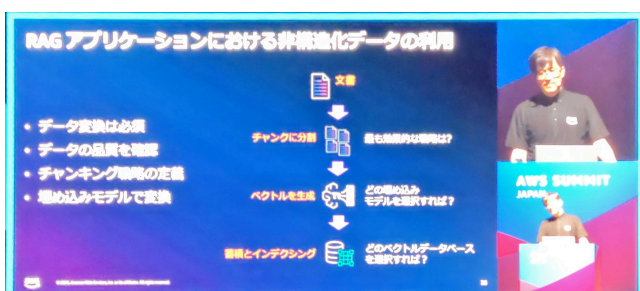
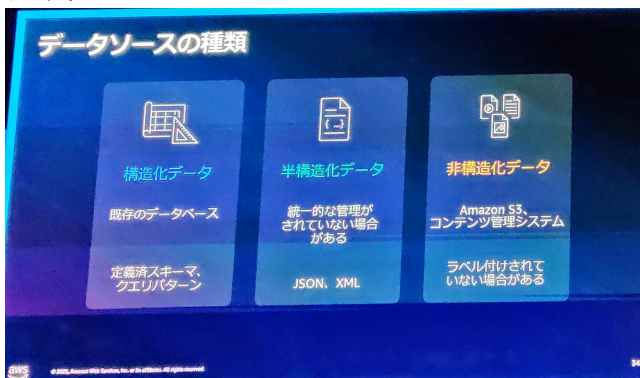


モジュラーRAG

BedrockAgents



データソース



チャンク分割やベクトルデータベースの選択

チャンキング方法の選択指針			
固定長	Fixed chunking	実装が容易	コンテキストを捉えやすい
スキーマを定義	<code><p>structural</p></code> <code><p>chunking</p></code>	スキーマがコンテキストを付与	スキーマの定義が必須
階層的	Hierarchical chunking	構造や関係性を捉えやすい	ドメイン知識が必要
ゼマンティック	Semantic chunking	文章間の関係性を抽出できる	より多くの時間やリソースが必要

適切なペクトルデータベースの選択

複雑性によってより
価値があるものは何でしょうか？

▼

	Amazon RDS w/ pyvector	Amazon DocumentDB	Amazon MemoryDB	Amazon Horus Analytics	Amazon OpenSearch Service	Amazon IDS w/ pyvector
EC2までのポロイド、ローコード対応						
	Amazon Bedrock をメタモデルのテキストベースで使用する					
検索のやすさとデータの構造						
検索性と統合	☆☆			☆☆	☆☆	
ハイブリッド検索機能		☆☆	☆☆	☆☆†	☆☆	☆☆
インテックスまたはクエリゆ チューニング	☆☆	☆☆			☆☆	☆☆
サーバーレスリリース	利用可能				利用可能	
低レイテンシー/リアルタイム	☆☆	☆☆	☆☆	☆☆	☆☆	☆☆
高いクエリスループット	☆☆	☆☆	☆☆	☆☆	☆☆	☆☆
価値/パフォーマンス	☆☆	☆☆	☆☆	☆☆	☆☆	☆☆

2025 © 2025, Amazon Web Services, Inc. or its affiliates. All rights reserved. | [Go to the top of the page](#)

† GraphRAGは、ベクトル検索とグラフ探索の組み合わせ

39



ビッグデータ基盤アーキテクチャのベストプラクティス

疎結合なシステムを構築する

- データ → 保存 → 処理 → 保存 → 分析 → 回答

適切なツールを選ぶ

- データ構造、レイテンシー、スループット、アクセスパターン

マネージドサービスとサーバーレスサービスを活用する

- スケラブル/弾縮性、可用性、信頼性、安全

ログ中心のデザインパターンを使用する

- (データレイク内の) 不変ログ、およびマテリアライズドビュー

コスト意識を高める

- ビッグデータ ≠ 大きなコスト



AWSSUMMIT
JAPAN



AWSSUMMIT
JAPAN



© 2019 Amazon Web Services, Inc. or its affiliates. All rights reserved.

RAGに適したデータアーキテクチャの選択

フロントエンドデータリソースレイヤー	バックエンドデータパイプライン
ミリ秒  信頼性 & ベクトルデータベース 秒  Amazon Redshift  Amazon Athena  データレイク ユーザーエージェント応答時間 + データ構造 + アクセスパターン	マイクロ秒 データ鮮度 (リアルタイムからの遅延) + データパターン (追記、更新) ミリ秒：追記または更新  +  信頼性 & ベクトルデータベースへのストリーミング 秒：追記または更新  +  Amazon Redshift へのストリーミング 数分以内、追記のみ  +  OTF データレイクへのストリーミング ストリーミングバッチ 数分以上、更新  +  OTF データレイクへバッチ処理

© 2023 Amazon Web Services, Inc. or its affiliates. All rights reserved.

[illegible][illegible]

データ共有とガバナンス

チャットボットチーム (コンシューマー)

Amazon Bedrock, AWS Glue, Amazon Athena

統合ポリシー管理
一元化されたガバナンスと監査
フェデレーションアクセスコントロール
組織全体での共有

フェデレーションカタログ

Amazon S3 (プロデューサー), Amazon Redshift (プロデューサー)

Amazon SageMaker Catalog

AWS SUMMIT JAPAN

AWS Glue を使用してデータ品質を担保する

データ品質定義言語 (DQL)

データ品質ルールを作成して再利用するための宣言型言語:

簡易な書き方
直感的
複雑なルールをサポート
再利用可能で導入が容易
SQL ベースのルールを作成

```
rules = [
    {
        "unique": "policy-id",
        "column": "collision_coverage_amt" between 50000 and 1000000
    }
]
```

Data Quality Definition Language (DQL)

AWS SUMMIT JAPAN

データ共有とリネージ

データ Lake データセット

フェデレーション データセット (プロデューサー)

チャットボット (コンシューマー)

Amazon SageMaker Catalog で実現する、データ提供者と利用者のためのデータ共有プラットフォームの構成

データの出所や流れを追跡し、常に正確かつ最新であることを保つことが重要

AWS SUMMIT JAPAN

アーキテクチャまとめ

フロントエンドデータサービスレイヤー

バックエンドデータパイプライン

データ取り込み

エンドユーザー

生成 AI モデル

データコンテキスト

データレイク

ストリーミングソース

バッチソース

データガバナンス

AWS SUMMIT JAPAN

